

دانشگاه تبریز
دانشکده علوم ریاضی
گروه آمار

گزارش کار پروژه دوره کارشناسی رشته آمار

عنوان:

پیش‌بینی قیمت مسکن با استفاده از رگرسیون خطی

دانشجو:

امیرعلی نعمتی ليقوان

استاد راهنما:

دکتر داریوش نجارزاده

ترم هفتم - ۱۴۰۵

چکیده

در این گزارش، فرایند کامل مدل‌سازی برای پیش‌بینی قیمت مسکن با استفاده از رگرسیون خطی چندگانه ارائه شده است. مجموعه داده‌ی مورد استفاده شامل ۵۰۰ رکورد و ۱۰ ویژگی عددی (متراژ، تعداد اتاق خواب، تعداد حمام، تعداد طبقات، سال ساخت، وجود حیاط، وجود استخر، اندازه گاراژ، امتیاز موقعیت مکانی و فاصله تا مرکز شهر) به همراه متغیر هدف قیمت است. پیش از مدل‌سازی، مراحل پیش‌پردازش داده شامل بررسی مقادیر گم‌شده، شناسایی داده‌های پرت با روش دامنه میان‌چارکی (IQR)، بررسی چولگی و امکان تبدیل لگاریتمی و مقیاس‌بندی ویژگی‌ها (نرمال‌سازی Min-Max و استانداردسازی) انجام شد.

سپس تحلیل همبستگی بین ویژگی‌ها و متغیر هدف، و همچنین تحلیل مؤلفه‌های اصلی (PCA) با استفاده از تجزیه مقادیر ویژه ماتریس کوواریانس صورت گرفت. در نهایت دو مدل رگرسیون خطی — یکی بر پایه‌ی ویژگی‌های استاندارد شده‌ی اصلی و دیگری بر پایه‌ی مؤلفه‌های اصلی حاصل از PCA — آموزش داده شد.

نتایج نشان می‌دهد مدل پایه به ضریب تعیین ۰,۹۷۶۷، روی داده‌ی آموزش و ۰,۹۷۰۹، روی داده‌ی آزمون دست یافته و مترآژ بنا و تعداد اتاق خواب مهم‌ترین پیش‌بینی‌کننده‌های قیمت هستند. تحلیل مؤلفه‌های اصلی نشان داد واریانس تقریباً به‌طور یکنواخت میان تمام ۱۰ مؤلفه توزیع شده و برای پوشش ۹۵٪ واریانس، هر ۱۰ مؤلفه لازم است؛ به همین دلیل PCA کاهش بعد معناداری ایجاد نکرد و مدل مبتنی بر آن دقیقاً همان عملکرد مدل پایه را داشت.

کلیدواژه‌ها: پیش‌بینی قیمت مسکن، رگرسیون خطی، پیش‌پردازش داده، تحلیل همبستگی، تحلیل مؤلفه‌های اصلی (PCA).

فهرست مطالب

2	چکیده.....
3	فهرست مطالب.....
4	فصل ۱ - مقدمه.....
4	۱.۱ بیان مسئله.....
4	۱.۲ اهداف پروژه.....
4	۱.۳ ساختار گزارش.....
5	فصل ۲ - مبانی نظری.....
5	۲.۱ رگرسیون خطی چندگانه.....
5	۲.۲ پیش‌پردازش داده.....
6	۲.۳ تحلیل همبستگی.....
7	۲.۴ تحلیل مؤلفه‌های اصلی (PCA).....
8	فصل ۳ - روش انجام کار.....
8	۳.۱ معرفی مجموعه داده.....
8	۳.۲ ابزارها و کتابخانه‌ها.....
8	۳.۳ مراحل پیش‌پردازش.....
9	۳.۴ پیاده‌سازی تحلیل همبستگی.....
9	۳.۵ پیاده‌سازی تحلیل مؤلفه‌های اصلی.....
9	۳.۶ پیاده‌سازی مدل‌سازی رگرسیون خطی.....
10	فصل ۴ - تحلیل و نتایج.....
10	۴.۱ آمار توصیفی داده.....
10	۴.۲ نتایج بررسی مقادیر گم‌شده.....
10	۴.۳ نتایج شناسایی داده‌های پرت.....
11	۴.۴ نتایج بررسی چولگی.....
11	۴.۵ نتایج وینزوریزیشن.....
11	۴.۶ نتایج مقیاس‌بندی ویژگی‌ها.....
12	۴.۷ نتایج تحلیل همبستگی.....
12	۴.۸ نتایج تحلیل مؤلفه‌های اصلی.....
13	۴.۹ نتایج مدل‌سازی رگرسیون خطی.....
14	۴.۱۰ جمع‌بندی و بحث.....
16	فصل ۵ - نتیجه‌گیری و پیشنهادات.....
16	۵.۱ جمع‌بندی.....
16	۵.۲ محدودیت‌های پروژه.....
16	۵.۳ پیشنهادات برای کارهای آینده.....
17	منابع.....

فصل ۱ - مقدمه

۱.۱ بیان مسئله

قیمت مسکن یکی از مهم‌ترین شاخص‌های اقتصادی در هر جامعه است و پیش‌بینی دقیق آن برای خریداران، فروشندگان، سرمایه‌گذاران، بانک‌ها و سیاست‌گذاران اهمیت زیادی دارد. قیمت یک واحد مسکونی معمولاً تابعی از ترکیبی از ویژگی‌های فیزیکی ملک (مانند مترائ، تعداد اتاق، تعداد طبقات)، امکانات جانبی (مانند حیاط، استخر، گاراژ) و ویژگی‌های موقعیت مکانی (مانند فاصله تا مرکز شهر و امتیاز موقعیت) است. با توجه به در دسترس بودن داده‌های ساخت‌یافته درباره‌ی این ویژگی‌ها، استفاده از روش‌های آماری و یادگیری ماشین برای مدل‌سازی رابطه‌ی میان این ویژگی‌ها و قیمت، رویکردی رایج و کارآمد است.

در این پروژه، هدف ساخت یک مدل پیش‌بینی قیمت مسکن بر پایه‌ی رگرسیون خطی چندگانه است؛ روشی که به دلیل سادگی، قابلیت تفسیرپذیری ضرایب و کارایی محاسباتی، همچنان یکی از پرکاربردترین ابزارها در تحلیل داده‌های جدولی به شمار می‌رود.

۱.۲ اهداف پروژه

- پیش‌پردازش و آماده‌سازی مجموعه‌داده‌ی مربوط به ویژگی‌های املاک مسکونی
- شناسایی و بررسی داده‌های پرت و کجی توزیع متغیرها
- بررسی میزان و جهت همبستگی هر ویژگی با قیمت مسکن
- کاهش بعد داده با استفاده از تحلیل مؤلفه‌های اصلی (PCA) و بررسی اثربخشی آن
- ساخت و ارزیابی یک مدل رگرسیون خطی برای پیش‌بینی قیمت مسکن
- مقایسه‌ی عملکرد مدل رگرسیون بر پایه‌ی ویژگی‌های اصلی در برابر مدل بر پایه‌ی مؤلفه‌های اصلی

۱.۳ ساختار گزارش

این گزارش در پنج فصل تنظیم شده است. فصل دوم مبانی نظری روش‌های به‌کاررفته را معرفی می‌کند. فصل سوم روش انجام کار و جزئیات پیاده‌سازی را شرح می‌دهد. فصل چهارم نتایج به‌دست‌آمده از هر مرحله را ارائه و تحلیل می‌کند. فصل پنجم نیز به جمع‌بندی، بیان محدودیت‌ها و ارائه‌ی پیشنهادات برای کارهای آینده اختصاص دارد.

فصل ۲ - مبانی نظری

۲.۱ رگرسیون خطی چندگانه

رگرسیون خطی چندگانه روشی آماری برای مدل‌سازی رابطه‌ی خطی بین یک متغیر پاسخ پیوسته (در اینجا قیمت مسکن) و مجموعه‌ای از متغیرهای مستقل (ویژگی‌های ملک) است. مدل به‌صورت زیر تعریف می‌شود:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

که در آن y متغیر پاسخ، x_1 تا x_p متغیرهای مستقل، β_0 عرض از مبدأ، β_1 تا β_p ضرایب رگرسیون و ε جمله خطا است. ضرایب مدل معمولاً با روش کمترین مربعات معمولی (OLS) برآورد می‌شوند؛ روشی که مجموع مربعات باقی‌مانده‌ها (تفاضل بین مقادیر واقعی و پیش‌بینی‌شده) را کمینه می‌کند.

برای ارزیابی کیفیت برازش مدل، از ضریب تعیین (R^2) استفاده می‌شود که نسبت واریانس متغیر پاسخ را نشان می‌دهد که توسط متغیرهای مستقل توضیح داده شده است. مقدار R^2 بین صفر و یک است؛ هرچه به یک نزدیک‌تر باشد، برازش مدل بهتر است. برای سنجش تعمیم‌پذیری مدل، R^2 معمولاً هم روی داده‌ی آموزش و هم روی داده‌ی آزمون (که مدل در فرایند آموزش آن را ندیده) محاسبه می‌شود؛ فاصله‌ی زیاد بین این دو مقدار نشانه‌ی بیش‌برازش (overfitting) است.

نکته‌ی مهم دیگر این است که وقتی متغیرهای مستقل پیش از مدل‌سازی استاندارد شوند (میانگین صفر و انحراف معیار یک)، اندازه‌ی ضرایب رگرسیون قابل مقایسه با یکدیگر می‌شود و می‌توان از آن‌ها برای سنجش اهمیت نسبی هر ویژگی در پیش‌بینی متغیر هدف استفاده کرد.

۲.۲ پیش‌پردازش داده

پیش از مدل‌سازی، کیفیت داده باید بررسی و در صورت نیاز اصلاح شود. مراحل رایج پیش‌پردازش که در این پروژه استفاده شده‌اند عبارت‌اند از:

بررسی مقادیر گمشده

وجود سلول‌های خالی در داده می‌تواند مدل‌سازی را مختل کند. روش رایج در صورت وجود مقادیر گمشده، جایگذاری (imputation) با میانگین یا میانه‌ی ستون است.

شناسایی داده‌های پرت با روش IQR

دامنه‌ی میان‌چارکی (Interquartile Range) به‌صورت $IQR = Q3 - Q1$ تعریف می‌شود که در آن $Q1$ و $Q3$ به‌ترتیب چارک اول و سوم توزیع هستند. مقادیری که خارج از بازه‌ی $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ قرار می‌گیرند، به‌عنوان داده‌ی پرت شناسایی می‌شوند. این روش نسبت به فرض نرمال بودن توزیع مقاوم است.

چولگی و تبدیل لگاریتمی

چولگی (Skewness) معیاری برای سنجش عدم تقارن توزیع یک متغیر است. مقدار چولگی نزدیک صفر نشان‌دهنده‌ی توزیع تقریباً متقارن است؛ درحالی‌که قدرمطلق چولگی بزرگتر از ۱ معمولاً به‌عنوان چولگی قابل‌توجه در نظر گرفته می‌شود. برای متغیرهای دارای چولگی زیاد و مقادیر نامنفی، تبدیل $\log(1+x)$ (یعنی $\log_{1p}$) رایج‌ترین روش برای کاهش چولگی و نزدیک‌تر کردن توزیع به توزیع نرمال است.

حذف داده‌های پرت

وینزوریزیشن (Winsorization) روشی برای محدود کردن اثر داده‌های پرت است که در آن مقادیر حدی (مثلاً ۵٪ پایین و ۵٪ بالای توزیع) به نزدیکترین مقدار مجاز کاهش یا افزایش داده می‌شوند، بدون آنکه رکورد از داده حذف شود.

مقیاس‌بندی Min-Max و استانداردسازی

مقیاس‌بندی Min-Max مقادیر هر ویژگی را به بازه‌ی [۰, ۱] نگاشت می‌کند:

$$x' = (x - x_{\min}) / (x_{\max} - x_{\min})$$


استانداردسازی (Z-score) نیز هر ویژگی را به میانگین صفر و انحراف معیار یک تبدیل می‌کند:

$$z = (x - \mu) / \sigma$$

استانداردسازی به‌ویژه پیش از اجرای PCA ضروری است، زیرا PCA بر پایه‌ی واریانس عمل می‌کند و بدون استانداردسازی، ویژگی‌هایی با مقیاس بزرگتر (مانند متر اژ) به‌طور مصنوعی بر مؤلفه‌های اصلی مسلط می‌شوند.

۲.۳ تحلیل همبستگی

ضریب همبستگی پیرسون میزان و جهت رابطه‌ی خطی بین دو متغیر پیوسته را اندازه می‌گیرد و بین -۱ و ۱ متغیر است. مقدار نزدیک به ۱ نشان‌دهنده‌ی همبستگی مثبت قوی، نزدیک به -۱ نشان‌دهنده‌ی همبستگی منفی قوی، و نزدیک به صفر نشان‌دهنده‌ی نبود رابطه‌ی خطی معنادار است. در این پروژه، ماتریس همبستگی بین تمام ویژگی‌های استاندارد‌شده و متغیر قیمت محاسبه شد تا مشخص شود کدام ویژگی‌ها بیشترین ارتباط خطی را با قیمت دارند. به‌طور معمول، قدر مطلق همبستگی بزرگتر از ۰,۵ به‌عنوان همبستگی نسبتاً قوی در نظر گرفته می‌شود.



۲.۴ تحلیل مؤلفه‌های اصلی (PCA)

تحلیل مؤلفه‌های اصلی (Principal Component Analysis) روشی برای کاهش بعد داده است که مجموعه‌ای از متغیرهای همبسته را به مجموعه‌ای کوچکتر از متغیرهای ناهمبسته به نام «مؤلفه‌های اصلی» تبدیل می‌کند، به گونه‌ای که بیشترین واریانس ممکن در داده‌ی اصلی حفظ شود.

روش محاسبه به این صورت است: ابتدا ماتریس کوواریانس ویژگی‌های استاندارد شده محاسبه می‌شود. سپس مقادیر ویژه (eigenvalues) و بردارهای ویژه (eigenvectors) این ماتریس به دست می‌آید. هر بردار ویژه جهت یک مؤلفه‌ی اصلی را در فضای ویژگی‌ها مشخص می‌کند (به آن‌ها «بارهای عاملی» یا loadings نیز گفته می‌شود) و مقدار ویژه‌ی متناظر، میزان واریانس است که آن مؤلفه توضیح می‌دهد. مؤلفه‌ها بر اساس مقدار ویژه به صورت نزولی مرتب می‌شوند تا مؤلفه‌ی اول بیشترین واریانس را در بر بگیرد.

نسبت واریانس توضیح داده شده (Explained Variance Ratio) از تقسیم مقدار ویژه‌ی هر مؤلفه بر مجموع تمام مقادیر ویژه به دست می‌آید. با استفاده از این نسبت‌ها و مجموع تجمعی (cumulative sum) آن‌ها، می‌توان تعیین کرد که برای پوشش سطح مشخصی از واریانس کل (مثلاً ۹۵٪) به چند مؤلفه نیاز است. اگر تعداد کمی از مؤلفه‌های اول بتوانند بخش زیادی از واریانس را توضیح دهند، PCA می‌تواند بعد داده را به طور معناداری کاهش دهد؛ اما اگر واریانس به طور یکنواخت میان تمام مؤلفه‌ها پخش شده باشد (که نشانه‌ی همبستگی پایین بین ویژگی‌های اصلی است)، PCA کاهش بعد چندانی ایجاد نمی‌کند.

فصل ۳ - روش انجام کار

۳.۱ معرفی مجموعه داده

مجموعه داده‌ی مورد استفاده در این پروژه شامل ۵۰۰ رکورد مربوط به واحدهای مسکونی است. پس از حذف ستون شناسه (ID) که صرفاً یک شماره‌ی رکورد بوده و اطلاعات پیش‌بینی‌کننده‌ای ندارد، ۱۰ ویژگی ورودی و یک متغیر هدف باقی می‌ماند:

توضیح	نوع	ستون
متر از بنا (فوت مربع)	پیوسته	Feet_Square
تعداد اتاق خواب	گسسته	Bedrooms_Num
تعداد حمام	گسسته	Bathrooms_Num
تعداد طبقات	گسسته	Floors_Num
سال ساخت	گسسته	Built_Year
وجود حیاط	دودویی (۱/۰)	Garden_Has
وجود استخر	دودویی (۱/۰)	Pool_Has
اندازه گاراژ	پیوسته	Size_Garage
امتیاز موقعیت مکانی (۰ تا ۱۰)	پیوسته	Score_Location
فاصله تا مرکز شهر (کیلومتر)	پیوسته	Center_to_Distance
قیمت ملک	پیوسته (هدف)	Price

لازم به ذکر است فایل خام (پیش از پردازش) مجموعه داده در دسترس نبوده و کار بر روی نسخه‌ای از پیش‌پردازش‌شده‌ی آن (processed_dataset_estate_real.csv) انجام شده است.

۳.۲ ابزارها و کتابخانه‌ها

پیاده‌سازی این پروژه با زبان برنامه‌نویسی Python و کتابخانه‌های زیر انجام شده است:

- pandas و numpy برای بارگذاری، پاکسازی و پردازش داده
- matplotlib و seaborn برای تجسم داده (نمودارهای پراکندگی، نقشه‌ی حرارتی همبستگی)
- scipy.stats.mstats.winsorize برای وینزوریزیشن
- scikit-learn (StandardScaler، MinMaxScaler، PCA، LinearRegression، train_test_split، r2_score) برای مقیاس‌بندی، کاهش بعد، مدل‌سازی و ارزیابی

۳.۳ مراحل پیش‌پردازش

- بارگذاری داده و بازرسی اولیه: بارگذاری فایل CSV و مشاهده‌ی چند رکورد اول و آمار توصیفی برای شناخت کلی داده.
- پاکسازی ستون‌ها: حذف فاصله‌های اضافی از نام ستون‌ها و حذف ستون ID که فاقد ارزش پیش‌بینی‌کنندگی است.

- بررسی مقادیر گمشته: شمارش مقادیر خالی در هر ستون؛ در صورت وجود، جایگذاری با میانگین ستون در نظر گرفته شده بود (هرچند در عمل نیازی به آن نبود).
- تحلیل اکتشافی داده (EDA): رسم نمودار پراکندگی هر ویژگی در برابر قیمت برای بررسی بصری الگوی رابطه‌ی هر متغیر با متغیر هدف.
- شناسایی داده‌های پرت با روش IQR: اعمال روش دامنهی میان‌چارکی بر تمام ویژگی‌ها و متغیر هدف برای شمارش و درصد داده‌های پرت هر ستون.
- بررسی چولگی و تبدیل لگاریتمی شرطی: محاسبه‌ی چولگی هر ستون و اعمال تبدیل $\log_{10}$ تنها بر ستون‌هایی که قدرمطلق چولگی آن‌ها بیشتر از ۱ و مقادیرشان نامنفی باشد.
- وینزوریزیشن شرطی: اعمال وینزوریزیشن (با حدود ۵٪ در هر دو انتها) تنها بر ستون‌هایی که بیش از ۱٪ داده‌ی پرت داشتند.
- مقیاس‌بندی Min-Max: نگاشت تمام ویژگی‌های عددی به بازه‌ی $[0, 1]$.
- استانداردسازی: تبدیل ویژگی‌های مقیاس‌بندی‌شده به میانگین صفر و انحراف معیار یک، آماده برای تحلیل همبستگی، PCA و مدل‌سازی.

۳.۴ پیاده‌سازی تحلیل همبستگی

پس از استانداردسازی، ماتریس همبستگی پیرسون بین تمام ویژگی‌ها و متغیر قیمت محاسبه شد. نتایج هم به صورت جدول عددی و هم با دو نمودار — نقشه‌ی حرارتی (heatmap) ماتریس کامل همبستگی و نمودار میله‌ای افقی همبستگی هر ویژگی با قیمت — نمایش داده شدند.

۳.۵ پیاده‌سازی تحلیل مؤلفه‌های اصلی

ماتریس کوواریانس ویژگی‌های استاندارد شده محاسبه و با تابع `np.linalg.eigh` به مقادیر ویژه و بردارهای ویژه تجزیه شد. از آنجا که این تابع مقادیر ویژه را به صورت صعودی برمی‌گرداند، ترتیب آن‌ها به نزولی تغییر یافت. سپس نسبت واریانس توضیح داده شده و مجموع تجمعی آن محاسبه شد و کوچکترین تعداد مؤلفه‌ی لازم برای پوشش حداقل ۹۵٪ واریانس کل تعیین گردید.

۳.۶ پیاده‌سازی مدل‌سازی رگرسیون خطی

داده به نسبت ۸۰٪ آموزش و ۲۰٪ آزمون تقسیم شد (با `random_state=42` برای تکرارپذیری). دو مدل رگرسیون خطی آموزش داده شد:

- مدل پایه: رگرسیون خطی مستقیماً روی ۱۰ ویژگی استاندارد شده‌ی اصلی.
 - مدل مبتنی بر PCA: ابتدا داده‌ی آموزش/آزمون به فضای مؤلفه‌های اصلی منتقل شد؛ سپس رگرسیون خطی روی این مؤلفه‌ها آموزش دید.
- عملکرد هر دو مدل با ضریب تعیین (R^2) روی داده‌ی آموزش و آزمون سنجیده شد تا میزان تعمیم‌پذیری و همچنین اثر کاهش بعد بر عملکرد مدل ارزیابی شود.

فصل ۴ - تحلیل و نتایج

۴.۱ آمار توصیفی داده

جدول زیر آمار توصیفی مجموعه داده (۵۰۰ رکورد) را پس از حذف ستون ID نشان می‌دهد:

ویژگی	میانگین	انحراف معیار	کمینه	چارک اول	میانه	چارک سوم	بیشینه
Square_Feet	174.64	74.67	51.27	110.32	178.29	239.03	298.24
Num_Bedrooms	2.96	1.44	1.00	2.00	3.00	4.00	5.00
Num_Bathrooms	1.98	0.82	1.00	1.00	2.00	3.00	3.00
Num_Floors	1.96	0.80	1.00	1.00	2.00	3.00	3.00
Year_Built	1957.60	35.49	1900	1926	1959	1988	2022
Has_Garden	0.54	0.50	0	0	1	1	1
Has_Pool	0.49	0.50	0	0	0	1	1
Garage_Size	30.17	11.58	10.00	20.00	30.00	41.00	49.00
Location_Score	5.16	2.85	0.00	2.76	5.21	7.73	10.00
Distance_to_Center	10.47	5.59	0.06	6.07	10.89	15.07	19.93
Price	582,209.63	122,273.39	276,892.47	503,080.34	574,724.11	665,942.30	960,678.27

میانگین قیمت مسکن در داده حدود ۵۸۲ هزار واحد پولی با انحراف معیار حدود ۱۲۲ هزار است که نشان‌دهنده پراکندگی نسبتاً زیاد قیمت در نمونه است.

۴.۲ نتایج بررسی مقادیر گمشده

بررسی تمام ۱۱ ستون نشان داد که هیچ مقدار گمشده‌ای در مجموعه داده وجود ندارد؛ بنابراین نیازی به جایگذاری (imputation) نبود.

۴.۳ نتایج شناسایی داده‌های پرت

با اعمال روش IQR بر تمام ویژگی‌ها و متغیر هدف، نتایج زیر به دست آمد:

ستون	تعداد داده‌ی پرت	درصد	حد پایین	حد بالا
Square_Feet	0	٪0.0	82.75-	432.10
Num_Bedrooms	0	٪0.0	1.00-	7.00
Num_Bathrooms	0	٪0.0	2.00-	6.00
Num_Floors	0	٪0.0	2.00-	6.00
Year_Built	0	٪0.0	1833	2081
Has_Garden	0	٪0.0	1.50-	2.50

حد بالا	حد پایین	درصد	تعداد داده‌ی پرت	ستون
2.50	1.50-	%0.0	0	Has_Pool
72.50	11.50-	%0.0	0	Garage_Size
15.19	4.70-	%0.0	0	Location_Score
28.58	7.44-	%0.0	0	Distance_to_Center
910,235.24	258,787.41	%0.2	1	Price

تنها متغیر Price یک داده‌ی پرت (معادل ۰,۲٪ از کل نمونه) داشت که مقداری بسیار ناچیز و غیرقابل توجه است. سایر ویژگی‌ها فاقد هرگونه داده‌ی پرت طبق این معیار بودند.

۴.۴ نتایج بررسی چولگی

جدول زیر مقدار چولگی هر ستون را به ترتیب نزولی قدرمطلق نشان می‌دهد:

چولگی	ستون
0.2086	Price
0.1448-	Has_Garden
0.1413-	Distance_to_Center
0.0836-	Location_Score
0.0686-	Garage_Size
0.0651	Num_Floors
0.0582	Year_Built
0.0576	Num_Bedrooms
0.0444	Num_Bathrooms
0.0321	Has_Pool
0.0256-	Square_Feet

از آنجا که قدرمطلق چولگی هیچ‌یک از ستون‌ها از آستانه‌ی ۱ فراتر نرفت، هیچ تبدیل لگاریتمی اعمال نشد. این نتیجه نشان می‌دهد توزیع تمام متغیرهای این مجموعه داده تقریباً متقارن است — رفتاری که با توجه به مصنوعی (synthetic) بودن محتمل مجموعه داده قابل انتظار است.

۴.۵ نتایج وینزوریزیشن

از آنجا که هیچ ستونی بیش از ۱٪ داده‌ی پرت نداشت (بیشترین مقدار، ۰,۲٪ برای Price بود)، شرط اعمال وینزوریزیشن برای هیچ ستونی برقرار نشد و این مرحله عملاً روی داده تأثیری نگذاشت.

۴.۶ نتایج مقیاس‌بندی ویژگی‌ها

پس از اعمال MinMaxScaler، تمام ۱۰ ویژگی به بازه‌ی [۰,۱] نگاشت شدند (کمینه = ۰، بیشینه = ۱ برای همه‌ی ستون‌ها). میانگین هر ستون پس از این تبدیل نزدیک ۰,۵ بود که نشان می‌دهد توزیع‌ها تقریباً متقارن‌اند:

ویژگی	میانگین (Min-Max)	انحراف معیار (Min-Max)
Square_Feet	0.500	0.302
Num_Bedrooms	0.490	0.360
Num_Bathrooms	0.488	0.410
Num_Floors	0.482	0.401
Year_Built	0.472	0.291
Has_Garden	0.536	0.499
Has_Pool	0.492	0.500
Garage_Size	0.517	0.297
Location_Score	0.516	0.286
Distance_to_Center	0.524	0.281

سپس با اعمال StandardScaler بر روی داده‌ی مقیاس‌بندی‌شده، تمام ویژگی‌ها به میانگین ۰ و انحراف معیار ۱ تبدیل شدند که آماده‌ی استفاده در تحلیل همبستگی و PCA است.

۴.۷ نتایج تحلیل همبستگی

جدول زیر همبستگی پیرسون هر ویژگی (استانداردشده) با قیمت را نشان می‌دهد:

ویژگی	همبستگی با Price
Num_Bedrooms	0.5640
Square_Feet	0.5586
Year_Built	0.4183
Num_Floors	0.1774
Num_Bathrooms	0.1567
Has_Pool	0.1366
Has_Garden	0.1092
Location_Score	0.0713
Garage_Size	0.0321
Distance_to_Center	0.0007

تنها دو ویژگی — تعداد اتاق خواب (۰,۵۶۴) و متراژ بنا (۰,۵۵۹) — همبستگی بالاتر از آستانه‌ی ۰,۵ با قیمت دارند و به‌عنوان قوی‌ترین پیش‌بینی‌کننده‌های خطی شناسایی می‌شوند. سال ساخت با همبستگی ۰,۴۱۸ در رتبه‌ی سوم قرار دارد. جالب توجه است که فاصله تا مرکز شهر تقریباً هیچ همبستگی خطی با قیمت ندارد (۰,۰۰۰۷)، که برخلاف انتظار رایج در بازار مسکن واقعی است و می‌تواند نشانه‌ای از ماهیت مصنوعی مجموعه داده باشد.

۴.۸ نتایج تحلیل مؤلفه‌های اصلی

تجزیه‌ی مقادیر ویژه‌ی ماتریس کوواریانس ۱۰ ویژگی استانداردشده، مقادیر ویژه‌ی زیر را به ما داد (به ترتیب نزولی):

مؤلفه	مقدار ویژه	نسبت واریانس توضیح داده شده	واریانس تجمعی
PC1	1.2751	%12.73	%12.73
PC2	1.2010	%11.99	%24.71
PC3	1.0918	%10.90	%35.61
PC4	1.0235	%10.21	%45.82
PC5	0.9903	%9.88	%55.71
PC6	0.9600	%9.58	%65.29
PC7	0.9248	%9.23	%74.52
PC8	0.8935	%8.92	%83.43
PC9	0.8852	%8.83	%92.27
PC10	0.7748	%7.73	%100.00

بارهای عاملی (loadings) چهار مؤلفه‌ی اول به شرح زیر است:

ویژگی	PC1	PC2	PC3	PC4
Square_Feet	0.252-	0.301	0.580	0.174
Num_Bedrooms	0.260-	0.064-	0.583-	0.086
Num_Bathrooms	0.404	0.054-	0.301	0.067
Num_Floors	0.382-	0.186-	0.257	0.440
Year_Built	0.058-	0.390-	0.256-	0.429
Has_Garden	0.264-	0.283-	0.133	0.291-
Has_Pool	0.008-	0.644	0.281-	0.048
Garage_Size	0.475	0.054	0.028-	0.183-
Location_Score	0.181-	0.316-	0.056	0.621-
Distance_to_Center	0.478-	0.345	0.027-	0.272-

نکته‌ی کلیدی این تحلیل آن است که واریانس تقریباً به‌طور یکنواخت میان ۱۰ مؤلفه پخش شده (هر مؤلفه بین ۷,۷٪ تا ۱۲,۷٪ واریانس را توضیح می‌دهد)، بدون آنکه چند مؤلفه‌ی اول سهم غالبی داشته باشند. در نتیجه، برای پوشش حداقل ۹۵٪ واریانس کل، هر ۱۰ مؤلفه (یعنی تمام ابعاد اصلی) لازم است و PCA در این مجموعه داده هیچ کاهش بعد معناداری ایجاد نمی‌کند. این رفتار با یافته‌های بخش ۴.۷ سازگار است:

چون همبستگی بین بیشتر ویژگی‌های اصلی پایین است، فضایی برای فشرده‌سازی اطلاعات در چند مؤلفه‌ی محدود وجود ندارد.

۴.۹ نتایج مدل‌سازی رگرسیون خطی

مدل پایه (۱۰ ویژگی استاندارد شده)

مقدار	معیار
0.9767	R^2 (آموزش)
0.9709	R^2 (آزمون)

ضرایب رگرسیون (بر پایه‌ی ویژگی‌های استاندارد شده، مرتب‌شده بر اساس قدر مطلق):

ضریب	ویژگی
75,321.63+	Square_Feet
72,280.15+	Num_Bedrooms
53,342.57+	Year_Built
24,867.54+	Num_Bathrooms
23,120.92+	Has_Pool
15,913.24+	Num_Floors
15,133.82+	Has_Garden
13,648.95+	Location_Score
13,134.16+	Garage_Size
10,513.85-	Distance_to_Center

مدل مبتنی بر PCA (۱۰ مؤلفه‌ی اصلی)

از آنجا که در بخش ۴.۸ مشخص شد پوشش ۹۵٪ واریانس به هر ۱۰ مؤلفه نیاز دارد (یعنی معادل کامل فضای اصلی، بدون کاهش بعد)، مدل رگرسیون عملاً بر روی یک چرخش متعامد (orthogonal rotation) از همان فضای ویژگی‌های اصلی برآزش داده شد و در نتیجه، عملکرد آن دقیقاً برابر مدل پایه بود:

مقدار	معیار
0.9767	R^2 (آموزش)
0.9709	R^2 (آزمون)

این نتیجه از نظر ریاضی کاملاً قابل انتظار است: چون هیچ مؤلفه‌ای حذف نشده، فضای برداری استفاده‌شده در رگرسیون تغییری نکرده و صرفاً پایه (basis) آن جابه‌جا شده است؛ رگرسیون خطی نیز نسبت به چرخش متعامد فضای ورودی، از نظر قدرت پیش‌بینی ناورد (invariant) است.

۴.۱۰ جمع‌بندی و بحث

- مدل رگرسیون خطی توانست با دقت بسیار بالایی (R^2 آزمون ≈ 0.97) قیمت مسکن را از روی ویژگی‌های ملک پیش‌بینی کند و فاصله‌ی کم بین R^2 آموزش و آزمون (0.9767 در برابر 0.9709) نشان می‌دهد مدل دچار بیش‌برآزش قابل‌توجهی نشده است.
- مترآز بنا و تعداد اتاق خواب هم در تحلیل همبستگی و هم در ضرایب مدل رگرسیون، به‌طور ثابت به‌عنوان مهم‌ترین عوامل تعیین‌کننده‌ی قیمت شناسایی شدند؛ سال ساخت در رتبه‌ی سوم اهمیت قرار دارد.

- فاصله تا مرکز شهر هم در همبستگی و هم در ضریب مدل، کمترین (و تنها ضریب منفی قابل توجه) اثر را نشان می‌دهد؛ یعنی با ثابت نگهداشتن سایر متغیرها، افزایش فاصله از مرکز شهر با کاهش جزئی قیمت همراه است — هم‌استا با انتظار عمومی بازار مسکن، هرچند شدت این اثر در این مجموعه داده بسیار ضعیف است.
- تحلیل مؤلفه‌های اصلی نشان داد ویژگی‌های این مجموعه داده تا حد زیادی از یکدیگر مستقل‌اند و واریانس به‌طور یکنواخت میان تمام ابعاد پخش شده است. برخلاف بسیاری از کاربردهای رایج PCA، در این مسئله استفاده از PCA کاهش بعد سودمندی ایجاد نکرد و مدل مبتنی بر آن دقیقاً هم‌ارز مدل پایه بود.

فصل ۵ - نتیجه‌گیری و پیشنهادات

۵.۱ جمع‌بندی

در این پروژه، یک خط لوله (pipeline) کامل برای پیش‌بینی قیمت مسکن طراحی و پیاده‌سازی شد که شامل پیش‌پردازش داده (بررسی مقادیر گم‌شده، شناسایی داده‌های پرت، بررسی چولگی، وینزوریزیشن شرطی و مقیاس‌بندی)، تحلیل همبستگی، تحلیل مؤلفه‌های اصلی و مدل‌سازی با رگرسیون خطی بود. مدل نهایی توانست با ضریب تعیین (دقت) ۰,۹۷۰۹ روی داده‌ی آزمون، عملکرد بسیار قابل‌قبولی در پیش‌بینی قیمت مسکن ارائه دهد. متراژ بنا، تعداد اتاق خواب و سال ساخت به‌عنوان مهم‌ترین عوامل تأثیرگذار بر قیمت شناسایی شدند.

۵.۲ محدودیت‌های پروژه

- مجموعه‌داده به احتمال زیاد مصنوعی (synthetic) است، چرا که برخی روابط (مانند نبود همبستگی معنادار بین فاصله از مرکز شهر و قیمت) با شواهد بازار مسکن واقعی همخوانی کامل ندارد.
- حجم نمونه (۵۰۰ رکورد) نسبتاً محدود است و نتایج ممکن است به مجموعه‌داده‌های واقعی و بزرگ‌تر به‌طور کامل قابل‌تعمیم نباشد.
- فایل خام (پیش از پردازش) مجموعه‌داده در دسترس نبود و تحلیل بر پایه‌ی نسخه‌ای از پیش‌پردازش‌شده انجام شد.

۵.۳ پیشنهادات برای کارهای آینده

- بررسی تعامل بین ویژگی‌ها (interaction terms) که ممکن است روابط غیرخطی پنهان را آشکار کند
- اعمال پروژه بر روی مجموعه‌داده‌ای واقعی و بزرگ‌تر برای سنجش تعمیم‌پذیری واقعی مدل

منابع

the project file :

- [1] Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.). Springer.
- [2] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning with Applications in Python. Springer.
- [3] Jolliffe, I. T. (2002). Principal Component Analysis (2nd ed.). Springer.
- [4] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
- [5] McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 51–56.
- [6] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). Introduction to Linear Regression Analysis (6th ed.). Wiley.